

Clasificación de Especies de Maleza en Imágenes de Campo Mediante CNN y Transfer Learning

Guillermo Mejía Uribe, Daniel Duque Rivera
guillermo.mejia@udea.edu.co, daniel.duquer@udea.edu.co

1. Contexto de aplicación

El control de malezas es uno de los problemas más costosos y persistentes de la agricultura extensiva. En Australia, por ejemplo, se estima que los productores gastan más de 1.500 millones de dólares australianos al año en controlar malezas, y pierden otros 2.500 millones en producción afectada por su presencia [1]. Aplicar herbicida de forma generalizada, en vez de dirigida, es ineficiente, costoso y tiene un impacto ambiental innecesario, porque se termina rociando tanto la maleza como la vegetación nativa de alrededor.

Una alternativa que ha tomado fuerza es la robótica de control selectivo: vehículos terrestres con cámara que identifican visualmente la especie de maleza presente y accionan un sistema de aspersión dirigido solo sobre esa planta. El cuello de botella de esta solución no es mecánico, es de percepción: se necesita un modelo capaz de reconocer, en tiempo real y bajo condiciones reales de campo (iluminación cambiante, fondos complejos, oclusión parcial), qué especie aparece en cada imagen que captura el robot [1].

Este proyecto trabaja justamente ese problema de percepción, usando el dataset DeepWeeds [1], recolectado en pastizales (rangeland) del norte de Australia, un entorno bastante más variable y difícil que un cultivo controlado. Vale aclarar que, aunque mi interés inicial al empezar el curso estaba más orientado al sector minero, el criterio que terminó pesando más para elegir este dataset fue la solidez metodológica y la existencia de un baseline académico verificable con el que contrastar resultados. La tarea que se resuelve aquí —clasificar visualmente bajo condiciones de campo no controladas— es en todo caso transferible conceptualmente a otros problemas de clasificación de imágenes en terreno, como identificar tipos de roca o de suelo.

2. Objetivo de machine learning

Se busca predecir la especie de maleza presente en una imagen RGB capturada en campo, usando únicamente la información visual de esa imagen. En otras palabras: dada una imagen, se quiere clasificarla en una de 9 categorías posibles, 8 especies de maleza de importancia nacional para Australia, o una clase “Negative” que agrupa toda la vegetación nativa y fondos donde no hay ninguna de esas 8 especies.

Se eligió predecir la especie exacta, y no solo “maleza sí/no”, porque cada especie requiere un herbicida y una estrategia de control distintos [1]. Y se parte solo de la imagen RGB, sin otros sensores, porque esa es la información que realmente capta el sistema óptico instalado en el robot de referencia del proyecto original (AutoWeed) [1]: el objetivo de ML quedó definido por la información que de verdad va a estar disponible en el momento de decidir, no al revés.

3. Dataset

DeepWeeds [1] es un dataset público disponible en Kaggle [7] (imsparsh/deepweeds) y en el repositorio oficial en GitHub (AlexOlsen/DeepWeeds), también distribuido a través de TensorFlow Datasets. Está compuesto por 17.509 imágenes RGB de 256×256 píxeles en formato JPG, con un tamaño total en disco de aproximadamente 470 MB.

Antes de trabajar con él se hizo una auditoría propia (análisis exploratorio) que confirmó: 0 archivos faltantes, 0 archivos corruptos y 0 duplicados exactos (verificado por hash MD5 sobre las 17.509 imágenes), además de consistencia total entre las etiquetas del CSV y las imágenes en disco. El dataset trae 5 particiones oficiales de entrenamiento/validación/prueba (aprox. 60% / 20% / 20% cada una), sobre las que se verificó que no hay fuga de datos entre los conjuntos de entrenamiento y de prueba.

Tabla 1. Distribución de clases del dataset DeepWeeds (verificada en auditoría propia sobre las 17.509 imágenes).

Especie	Imágenes	Porcentaje
Negative (sin maleza objetivo)	9.106	52,0%
Chinee apple	1.125	6,4%
Siam weed	1.074	6,1%
Lantana	1.064	6,1%
Prickly acacia	1.062	6,1%
Parkinsonia	1.031	5,9%
Parthenium	1.022	5,8%
Snake weed	1.016	5,8%
Rubber vine	1.009	5,8%
Total	17.509	100%

La clase Negative concentra más de la mitad de las imágenes, mientras las 8 clases de maleza están razonablemente balanceadas entre sí. El ratio de desbalance (clase mayoritaria sobre minoritaria) es de 9,02, lo cual se considera un desbalance significativo y va a requerir tratamiento explícito —ponderación de clases y métricas por clase— durante el entrenamiento [2].

4. Métricas de desempeño

De machine learning: como el desbalance de clases puede hacer que el accuracy global esconda un mal desempeño en clases minoritarias, se reportará el accuracy general (para poder comparar directamente con el baseline de Olsen et al. de 95,7% [1]), junto con F1-score por clase, F1 macro y la matriz de confusión completa para el análisis de errores. Esto sigue la recomendación de Farhadpour et al. [2], quienes muestran que las métricas “compuestas” (accuracy o F1 macro solos) pueden ocultar un desempeño pobre en clases específicas, y recomiendan complementarlas siempre con métricas desglosadas por clase.

De negocio: en un robot de aspersión selectiva no todos los errores cuestan lo mismo. Un falso positivo (clasificar vegetación nativa como maleza) implica rociar herbicida donde no se necesita, con costo económico y ambiental directo. Un falso negativo (no detectar una maleza real) la deja sin controlar, con impacto directo en la producción. Por eso se hará seguimiento específico de la tasa de falsos positivos sobre la clase Negative y del recall por especie, priorizando reducir ambos tipos de error por encima de solo maximizar el accuracy global. También se documentará el tiempo de inferencia por imagen, ya que la aplicación real exige procesar cada imagen en menos de 100 ms para poder operar a 10 km/h [1].

5. Referencias y resultados previos

Este proyecto se ubica en el Módulo 4 (Redes Convolucionales), combinando dos técnicas: (i) una CNN simple entrenada desde cero, que sirve de punto de referencia interno para poder cuantificar cuánto aporta realmente el transfer learning, y (ii) transfer learning con ResNet-50 preentrenada en ImageNet, primero con las capas base congeladas y luego con ajuste fino (fine-tuning) de las últimas capas. No se optó por el Módulo 5 (modelos de secuencia) porque el problema no tiene estructura temporal: cada imagen se clasifica de forma independiente, sin relación secuencial entre observaciones, así que una arquitectura convolucional espacial es la que corresponde a la naturaleza del dato.

La justificación de por qué el transfer learning debería ayudar —y no solo la evidencia empírica de que ayuda— viene de Yosinski et al. [3], quienes demuestran que las primeras capas de una CNN aprenden características genéricas (bordes, texturas, colores) que transfieren bien entre tareas distintas, mientras que las capas finales aprenden representaciones específicas de la tarea de origen. Esto es lo que sustenta congelar las capas base de ResNet-50 en una primera iteración y solo descongelar las últimas en el ajuste fino posterior: no es una elección arbitraria de hiperparámetros, sino consecuencia de cómo se distribuye la información dentro de la red.

Sobre resultados previos: el propio paper de DeepWeeds [1] reporta 95,7% de accuracy promedio con ResNet-50 (validación cruzada de 5 folds) y 95,1% con Inception-v3, y es el baseline principal contra el que se comparará este proyecto. Un trabajo posterior, Duong et al. [4], reentrenó ambas arquitecturas sobre el mismo dataset y las superó usando EfficientNet-B4 combinado con distintas estrategias de transfer learning (ImageNet, Adversarial Propagation, Noisy Student), llegando hasta 99,26% de accuracy —evidencia directa de que la estrategia de transfer learning elegida, no solo la arquitectura, tiene un impacto medible en este problema. Una revisión sistemática de 61 estudios sobre clasificación de malezas con CNN [5] confirma que ResNet, VGG y MobileNet están entre las arquitecturas más usadas en la literatura reciente, lo que respalda que partir de ResNet-50 es una elección razonable y no arbitraria.

Es importante aclarar que este proyecto no busca replicar el trabajo de Olsen et al. ni el de Duong et al., sino contrastarse con ellos: la meta es entender por qué el transfer learning mejora el desempeño frente a una CNN entrenada desde cero, identificar en qué clases específicas falla más el modelo —algo que ninguno de los trabajos anteriores analiza en profundidad— y documentar honestamente las limitaciones del enfoque propio. Como referencia adicional de contraste, dos Santos Ferreira et al. [6] aplicaron CNN a clasificación de malezas en cultivos de soya (un entorno mucho más controlado, con solo 4 clases) y obtuvieron más de 99% de accuracy, lo que ayuda a argumentar que la mayor dificultad de DeepWeeds no viene de la arquitectura, sino de la complejidad del entorno rangeland en el que fue recolectado.

Referencias

- [1] A. Olsen, D. A. Konovalov, B. Philippa, P. Ridd, J. C. Wood, J. Johns, W. Banks, B. Girgenti, O. Kenny, J. Whinney, B. Calvert, M. Rahimi Azghadi, and R. D. White, “DeepWeeds: A multiclass weed species image dataset for deep learning,” *Scientific Reports*, vol. 9, art. 2058, 2019.
- [2] S. Farhadpour, T. A. Warner, and A. E. Maxwell, “Selecting and interpreting multiclass loss and accuracy assessment metrics for classifications with class imbalance: Guidance and best practices,” *Remote Sensing*, vol. 16, no. 3, art. 533, 2024.
- [3] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?” in *Advances in Neural Information Processing Systems*, vol. 27, 2014, pp. 3320–3328.
- [4] L. T. Duong, T. B. Tran, N. H. Le, V. M. Ngo, and P. T. Nguyen, “Automatic detection of weeds: synergy between EfficientNet and transfer learning to enhance the prediction accuracy,” *Soft Computing*, vol. 28, pp. 5029–5044, 2024.
- [5] O. L. García-Navarrete, A. Correa-Guimaraes, and L. M. Navas-Gracia, “Application of convolutional neural networks in weed detection and identification: A systematic review,” *Agriculture*, vol. 14, no. 4, art. 568, 2024.
- [6] A. dos Santos Ferreira, D. M. Freitas, G. G. da Silva, H. Pistori, and M. T. Folhes, “Weed detection in soybean crops using ConvNets,” *Computers and Electronics in Agriculture*, vol. 143, pp. 314–324, 2017.
- [7] Im sparsh, “DeepWeeds,” Kaggle, 2019. [En línea]. Disponible en: <https://www.kaggle.com/datasets/im sparsh/deepweeds>